企业级Hadoop平台源码二次开发- (1)

一、课前准备

- 1. 安装idea
- 2. 下载hadoop源码

https://archive.apache.org/dist/hadoop/common/hadoop-2.7.0/hadoop-2.7.0-src.tar.gz

3. 将源码导入idea工具 (直接导入即可)

二、课堂主题

本节课给大家讲解Hadoop RPC原理和HDFS启动流程,为后面二次开发打下基础

三、课程目标

- 1. 掌握Hadoop RPC原理
- 2. 掌握HDFS 启动流程
- 3. 掌握阅读源码技巧(个人)

四、知识要点

1. 项目要点 (5分钟)

1.1 项目背景

公司集群已运行一年之多,现在集群为满足公司需求,计划将集群扩为300+节点,在过去一年的集群管理中收集到了一些Hadoop集群的bug和性能改造点,故成立了此项目对当前的Hadoop集群进行性能提升和Bug修复。

1.2 项目目标

提升集群性能,并且保证集群4个9稳定。

1.3 学习本项目的意义

- (1) 通过学习Hadoop的源码,掌握分布式系统设计的本质的思想。
- (2) 数据存储平台是大数据里面非常重要的一个环节。
- (3) 架构师的要求

2. 项目基础知识 (20分钟)

2.1 版本的选择

当前的Hadoop版本已经发展到Hadoop3.x版本了,但是现在业内大的趋势还是用的Hadoop2.X系列,故我们用的也是Hadoop2.X源码(hadoop2.7.0)

2.2 阅读大数据源码的思路

1. 掌握其网络通信架构(hadoop RPC)

分布式, 网络的通信

Hadoop : Hadoop RPC

Flink/Spark(1.5): Akka

- 2. 场景驱动的方式 (HDFS的源码)
- 3. 集群启动

NameNode

DataNode

- 4. 写数据的流程 (元数据管理)
- 5. 读数据的流程
- 6. 看源码的时候, 要画流程图/边写注释
- 7. 看核心类注释 (方式之一)
- 8. 连蒙带猜

2.3 Hadoop RPC

RPC(Remote Procedure Call)—远程(不同进程)过程(方法的)调用。

c/s 客户端/服务端 (不同进程)

客户端调用服务端的方法,方法的执行(服务端)

代码实现

pom依赖

```
/**

* 协议

* @author Administrator

*

*/

public interface ClientProtocol {
    long versionID=1234L;
    void makeDir(String path);

}
```

服务端代码

```
/**

* RPC服务端

* @author Administrator
```

```
public class NameNodeRpcServer implements ClientProtocol {
   /**
    * 创建目录
    */
    @override
    public void makeDir(String path) {
       System.out.println("服务端: "+path);
    public static void main(String[] args) throws Exception {
        Server server = new RPC.Builder(new Configuration())
        .setBindAddress("localhost")
        .setPort(9999)
        .setProtocol(ClientProtocol.class)
        .setInstance(new NameNodeRpcServer())
        .build();
        //启动服务端
        server.start();
   }
}
```

客户端代码

总结Hadoop RPC的特点:

- 1. RPC指的是不同进程的方法的调用,分别为客户端和服务端,并且是客户端调用服务端的方法,方 法的执行是在服务端。
- 2. 如果实现RPC的调用,必须要有一个协议,协议其实就是一个接口,里面有一个重要的特征,里面得有versionID
- 3. 服务端必须要实现协议(接口)
- 4. 凡是JPS命令能看到的服务,都是RPC的服务端

5. 如何构建一个RPC的服务端

6. 客户端是如何获取代理的?

我们猜测一下, NameNode的启动流程里面会有什么样的代码? 我们去验证一下!

```
public interface A{
  public long versionID=12L;
  void a();
public interface B{
  public long versionID=122L;
  void b();
}
public class NameNodeRPCServer implements A,B{
  public void a(){
  public void b(){
  }
    Server server = new RPC.Builder(new Configuration())
                    .setBindAddress("localhost")
                    .setPort(9999)
                    .setProtocol(ClientProtocol.class)
                    .setInstance(new NameNodeRpcServer())
                    .build();
  }
}
public class NameNOde{
    private NameNodeRpcServer rpcServer;
    public static void main(String[] args){
```

```
rpcServer= new NameNodeRpcServer()
}
```

场景驱动:

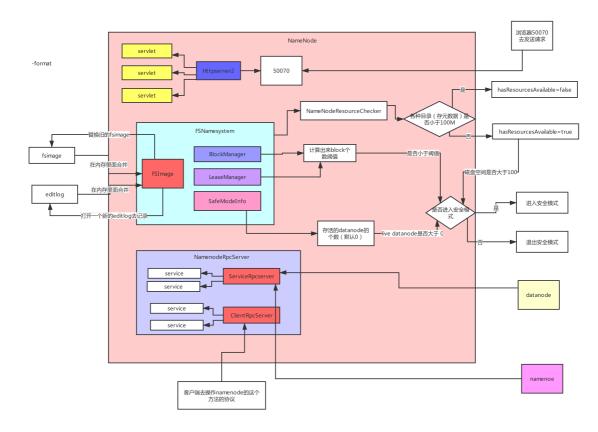
- 1. NameNode如何启动的?
- 2. DataNode是如何启动的? (
 - 1. 看一下核心的类的注释

2.

3. 源码流程讲解

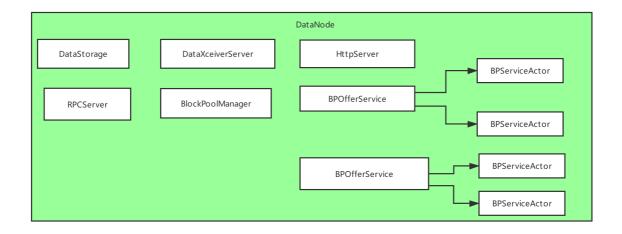
3.1 NameNode流程启动剖析(40分钟)

流程图:



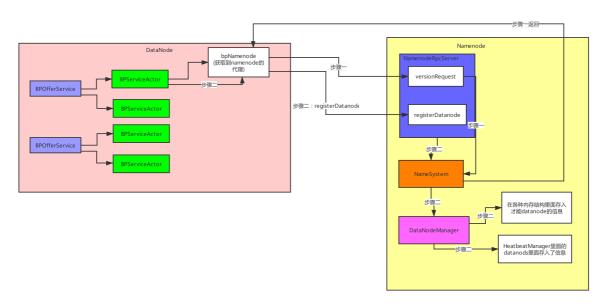
3.2 DataNode初始化 (10分钟)

流程图:



3.3 DataNode注册 (20分钟)

流程图:



五、招聘要求 (5分钟)

有效日期: 2019-09-25

基本要求: 年龄不限 | 性别不限

工作地点: 北京

职位描述:

1、负责大数据平台的设计和开发,负责hadoop、storm、spark、yarn等云计算平台的开发和优化;制定数据架构规范,指 导团队落地2、负责数据基础架构和数据处理体系的升级和优化,不断提升系统的稳定性和效率,为公司的业务提供大数据底 层平台的支持和保证; 3、大数据平台的数据采集、处理、存储以及挖掘分析的架构实现; 4、研究未来数据模型和计算框架的 创新与落地,包括但不限于以下领域: 大规模数据实时化、研发模式敏捷化、数据计算框架轻量化、数据模型组织方式业务化 等方面,参与制定并实践团队的技术发展路线;5、建立良好的公司内外的业界技术影响力;参与培养未来数据人才;有效辅导 团队, 提升数据研发能力。任职资格: 1、有很强的数据设计抽象能力, 善于从复杂的数据问题中找到关键路径; 2、有作为技 术负责人系统化解决问题的成功案例;有海量数据实践经验优先;3、熟悉目前正在发展的大数据分布式平台前沿技术的应 用;包括但不仅仅限于:hadoop、storm、spark、等;4、性格积极乐观,诚信,能自我驱动,有较强的语言表达能力;具 备强烈的进取心、求知欲及团队合作精神;具有良好的沟通、团队协作、计划和创新的能力;在数据业界有一定的影响力优 先,具有风控经验背景的人优先;5、能够开发创新而实际的分析方法以解决复杂的商业问题

大数据平台架构师-L00426(京东数字科技控... 40000-80000 元/月

[7] 分享

职位类型:技术 发布时间: 2019-07-25 有效日期: 2019-09-25

基本要求: 年龄不限 | 性别不限

工作地点: 北京

职位描述:

职责描述: 1、负责京东城市计算平台(数据平台)整体架构设计,大数据技术体系,以及大数据平台的整体规划; 2、搭建数 据平台技术框架,安排开发人员进行开发,并解决开发过程中细节问题;3、对数据平台安全性,数据质量保障方面进行深入 思考,保障平台数据安全和数据质量。任职要求:1、计算机/应用数学等相关专业、全日制本科以上学历;2、具有6年以上大 数据架构设计工作经验,主导过大型企业大数据平台的构建;3、熟悉Hadoop架构与生态圈(如:HDFS、Hive、HBASE、 MapReduce、Spark、Flink、Kafka、ElasticSearch、impala等);对hadoop生态圈组件既有广泛的了解,又对某些核心组 件有过深入开发经验;4、优秀的沟通理解能力,具备在高压力x境下推进工作的能力;5、具备快速学习能力,能快速掌握新 的开源技术框架; 6、有过时空大数据分析和处理经验优先。



大

大

大

<

职位详情



大数据存储研发工程师

60k-90k

北京·海淀区 / 本科及以上 / 5-10年



Nikki 🔼 🕍 1分钟前来过 BIGO·hrbp

立即沟通

平均1天回复 回复率100%

职位描述

存储

岗位职责:

- 1.进行HDFS或者Hbase存储技术栈的源码研究、二次开发、解决 实际业务中的问题与挑战;
- 2.打造业界领先的大数据存储系统、为海量数据及其上的大规模 数据挖掘、机器学习业务系统提供可靠、高效的支持;
- 3. 承担千台规模HDFS集群的管理工作,与业务一起解决性能优 化、容量规划、预算审计等问题,保障集群高效稳定经济运行。 岗位要求:
- 1.计算机或相关专业本科及以上学历,熟悉Java/Scala/C++/Go等 开发语言,2年以上工作经验。
- 2. 熟悉HDFS或者Hbase源码,有扎实的分布式存储理论基础;
- 3.有HDFS或Hbase社区贡献或者社区活跃者优先;
- 4 有大规模HDFS或者Hhase 生群管理和维护者优先:

可以聊

投递简历

六、总结 (5分钟)

- 1. 阅读源码需要用什么样的一些方式?
- 2. Hadoop RPC
- 3. 总结Hadoop RPC
- 4. 场景驱动的方式 -> namenode -> (类的注释,验证namendoe是否是RPC的服务端)
- 5. 启动HTTPServer 加载元数据 RPC 资源检查 判断是否进去安全
- 6. DataNode的启动 -> 场景驱动的方式 -> (类的注释,验证datanode是否是RPC的服务端)
- 7. 初始化了很多组件
- 8. RPC的代码
- 9. 注册流程

下次课:

10. 心跳

===========

1. 元数据管理 (高可用,如何抗住亿级流量?)

七、作业

1. 每位同学至少画一遍流程图

八、互动