Kafka企业常见面试题

1. Kafka数据积压如何处理?

参考建议:

- 1. 增加topic分区,增加消费者
- 2. 如果当天是重要的活动,那么可以考虑,业务降级,关闭不重要的业务,减少数据量

2. Kafka的分区为什么没有设计读写分离?

参考建议

1)如果读写分离,还得考虑数据一致性。 会带来数据延迟。 2)如果有压力可以靠扩**partition**来解决,所以读写分离的必要性不大

3. Kafka为什么读写效率高

参见建议:

写:

- 1. 内存池的设计
- 2. 批量发送数据默认200ms发送一次
- 3. 强势的网络架构 Reactor网络设计模式
- 4. 一直写的是队列,也就是内存写入,后续根据三层网络架构进行分发多线程处理
- 5. 顺序写磁盘
- 6. 零拷贝机制。减少了网络IO

读:

- 1. 跳表设计
- 2. 日志存储是稀疏索引设计,也就是双重定位都有索引。

4. kafka中生产数据的时候,如何保证写入的容错性?

设置发送数据是否需要服务端的反馈,有三个值0,1,-1

- 0: producer不会等待broker发送ack
- 1: 当leader接收到消息之后发送ack
- -1: 当所有的follower都同步消息成功后发送ack

request.required.acks=0

5. 说说Kafka的ISR副本同步队列

ISR(In-Sync Replicas),副本同步队列。ISR中包括Leader和Follower。如果Leader进程挂掉,会在ISR队列中选择一个服务作为新的Leader。有replica.lag.max.messages(延迟条数)和replica.lag.time.max.ms(延迟时间)两个参数决定一台服务是否可以加入ISR副本队列,在0.10版本移除了replica.lag.max.messages参数,防止服务频繁的进去队列。

任意一个维度超过阈值都会把Follower剔除出ISR,存入OSR(Outof-Sync Replicas)列表,新加入的Follower也会先存放在OSR中。

6. 哪些场景你会选择Kafka?

日志收集:一个公司可以用Kafka可以收集各种服务的log,通过kafka以统一接口服务的方式开放给各种consumer,例如hadoop、HBase、Solr等。

消息系统:解耦和生产者和消费者、缓存消息等。

用户活动跟踪: Kafka经常被用来记录web用户或者app用户的各种活动,如浏览网页、搜索、点击等活动,这些活动信息被各个服务器发布到kafka的topic中,然后订阅者通过订阅这些topic来做实时的监控分析,或者装载到hadoop、数据仓库中做离线分析和挖掘。

运营指标: Kafka也经常用来记录运营监控数据。包括收集各种分布式应用的数据,生产各种操作的集中反馈,比如报警和报告。

流式处理: 比如spark streaming和 Flink

7.Kafka 分区的目的?

分区对于 Kafka 集群的好处是:实现负载均衡。 分区对于消费者来说,可以提高并发度,提高效率。

8. Kafka 高效文件存储设计特点?

Kafka把topic中一个parition大文件分成多个小文件段,通过多个小文件段,就容易定期清除或删除已经消费完文件,减少磁盘占用。

通过索引信息可以快速定位message和确定response的最大大小。

通过index元数据全部映射到memory,可以避免segment file的IO磁盘操作。

通过索引文件稀疏存储,可以大幅降低index文件元数据占用空间大小

9.Kafka 是如何实现高吞吐率的?

Kafka是分布式消息系统,需要处理海量的消息,Kafka的设计是把所有的消息都写入速度低容量大的硬盘,以此来换取更强的存储能力,但实际上,使用硬盘并没有带来过多的性能损失。kafka主要使用了以下几个方式实现了超高的吞吐率:

- 1)顺序读写;
- 2) 零拷贝
- 3) 文件分段
- 4) 批量发送
- 5)数据压缩。

10. 可以对Kafka 进行监控的工具,你知道的有哪些?

比较流行的监控工具有:

KafkaOffsetMonitor

KafkaManager

Kafka Web Console

Kafka Eagle

JMX协议(可以用诸如jdk自带的jconsole来进行连接获取状态信息)

11. Kafka 分区数可以增加或减少吗? 说说你自己的理解?

我们可以使用 bin/kafka-topics.sh 命令对 Kafka 增加 Kafka 的分区数据,但是 Kafka 不支持减少分区数。Kafka 分区数据不支持减少是由很多原因的,比如减少的分区其数据放到哪里去?是删除,还是保留?删除的话,那么这些没消费的消息不就丢了。如果保留这些消息如何放到其他分区里面?追加到其他分区后面的话那么就破坏了 Kafka 单个分区的有序性。如果要保证删除分区数据插入到其他分区保证有序性,那么实现起来逻辑就会非常复杂。

12. 比较RabbitMQ与Apache Kafka

Apache Kafka的另一个选择是RabbitMQ。那么,让我们比较两者: 功能Apache Kafka- Kafka是分布式的、持久的和高度可用的,这里共享和复制数据RabbitMQ中没有此类功能性能速度Apache Kafka-达到每秒100000条消息。RabbitMQ-每秒20000条消息。

13. 说出三个Kafka 与传统消息系统之间的关键区别

参考建议:

- 1. Kafka 持久化日志,这些日志可以被重复读取和无限期保留
- 2. **Kafka** 是一个分布式系统:它以集群的方式运行,可以灵活伸缩,在内部通过复制数据提升容错能力和高可用性
- 3. Kafka 支持实时的流式处理

14. Kafka中的分区器、序列化器、拦截器是否了解?它们之间的处理顺序是什么?

参考建议:

- 1. 分区器:根据键值确定消息应该处于哪个分区中,默认情况下使用轮询分区,可以自行实现分区器接口自定义分区逻辑
- 2. 序列化器:键序列化器和值序列化器,将键和值都转为三进制流 还有反序列化器 将二进制流转为指定类型数据
- 3. 拦截器:两个方法 doSend()方法会在序列化之前完成 onAcknowledgement()方法在消息确认或失败时调用 可以添加多个拦截器按顺序执行

调用顺序: 拦截器doSend() -> 序列化器 -> 分区器

15. Kafka服务器能接收到的最大信息是多少?

参考建议:

默认Kafka服务器可以接收到的消息的最大大小是1000000字节。但是生产里面建议调大这个值,比如10M

16. kafka producer如何优化打入速度

- 1. 增加线程
- 2. 提高 batch.size
- 3. 增加更多 producer 实例
- 4. 增加 partition 数
- 5. 设置 acks=-1 时,如果延迟增大:可以增大 num.replica.fetchers (follower 同步数据的线程数)来调解;
- 6. 跨数据中心的传输:增加 socket 缓冲区设置以及 OS tcp 缓冲区设置。

17. 新增分区Spark 能发现吗

park Streaming针对kafka0.8.2及以前版本不能进行新增分区及topic发现,0.10以后版本是可以动态 检测新增分区和topic。

18. 如果leader crash时,ISR为空怎么办?

kafka在Broker端提供了一个配置参数: unclean.leader.election,这个参数有两个值:

true (默认):允许不同步副本成为leader,由于不同步副本的消息较为滞后,此时成为leader,可能会出现消息不一致的情况。

false: 不允许不同步副本成为leader, 此时如果发生ISR列表为空, 会一直等待旧leader恢复, 降低了可用性。

19. 如何保证Kafka数据不丢?

参考建议:

https://mp.weixin.qq.com/s?

 $\begin{tabular}{l} $$ $$ -biz=MzIzODIzNzEONQ==&mid=2654419241&idx=1&sn=282f997491c63b1511db4b8a95bdc9f5& chksm=f2fffd9fc58874898fe60b5df4a8e73b2ef77324eb16fb8b941c2d43c968408b5b3f81046e 1d&mpshare=1&scene=1&srcid=1227ty6jHytFyIum2etExaPx&sharer_sharetime=16090569216 39&sharer_shareid=4363c424a1c495d9e35704dc5e1dd27a&key=7a5a542d4d3c4fcba3db9ce20 799b8dbcb7e80ab44a240633acf117bd58b6e2801f13c9dcb66dc547cba0ce6e9a1bd59bef11a57b 71386e77159df19e89d9683cfe0d4999474877219088316625b6d4b816dea530f4c80cba58666c62 5fa35fb5b337fb886dfecbb3733930d256d0888f174259cdcd77489402cbd71b6955611&ascene=1 &uin=MTcyNzk1MjY2Mg%3D%3D&devicetype=Windows+10+x64&version=63000039&lang=zh_CN&exportkey=AbRnVwDQquU8AVZwgDgeDqc%3D&pass_ticket=cdnDJkdfAyJKJ2vptYrxktT5NjyY3Up YI6UZTZLv8RwZShdVeaBEorEQU5VpLwLr&wx_header=0 \\ \end{tabular}$

20. kafka数据重复的问题如何解决?

参考建议:

https://mp.weixin.qq.com/s?